

VOICE AI AGENT ENGINEERING

Automatización Inteligente de Llamadas con IA y n8n

JORGE QUINTAS BAEZ

n8n Expert

Voice AI Architect

ARQUITECTURA DE SOLUCION VOICE AI



ENFOQUES DE IMPLEMENTACION


A PLATFORM-CENTRIC

- + Retell AI / Vapi como cerebro de voz
- + n8n gestiona logica de negocio via webhooks
- + Menor latencia. Mas facil de desplegar.
- + Optimo para produccion y alto volumen.

B n8n COMO ORQUESTADOR

- + n8n controla STT + LLM + TTS completo
- + Twilio Webhook -> Whisper -> Claude -> ElevenLabs
- + Maximo control tecnico por componente.
- + Ideal para customizacion profunda.

MERCADO VOICE AI 2025-2026



PLATAFORMAS Y TECNOLOGIAS DOMINADAS



CASOS DE USO IMPLEMENTADOS



El mercado de Voice AI Agents alcanzo los \$47 mil millones en 2025 y se proyecta en \$89 mil millones para 2028. Las empresas que adoptan agentes de voz IA reportan reducciones de hasta el 70% en costes de atencion al cliente, con disponibilidad 24/7 y respuestas en menos de 600ms. La clave del exito esta en la correcta integracion de tres capas tecnologicas: la infraestructura telefonica, la plataforma de IA conversacional y la capa de automatizacion.

LAS 3 CAPAS TECNOLOGICAS

CAPA DE TELEFONIA E INFRAESTRUCTURA SIP

Gestiona el numero de telefono real, la red SIP/PSTN y el enrutamiento de llamadas. Es el punto de entrada fisico de la llamada al sistema. Debe ser un operador de telecomunicaciones con API programable y soporte de webhooks.

1

- Twilio - Telnyx - Vonage - Netelip - Plivo - Bandwidth
- Soporte SIP Trunk / PSTN directo
- Webhooks para eventos de llamada en tiempo real
- Numeros locales internacionales (+34, +1, etc.)

CAPA DE IA CONVERSACIONAL (VOICE AI PLATFORM)

Orquesta el pipeline STT (Speech-to-Text) + LLM (Language Model) + TTS (Text-to-Speech). Recibe el audio del operador telefonico, lo transcribe, genera una respuesta inteligente y la sintetiza de vuelta como voz natural.

2

- Retell AI - Vapi - Bland AI - ElevenLabs - Thoughtly
- Latencias desde 250ms hasta 800ms segun plataforma
- Compatibilidad con LLMs: Claude, GPT-4o, Gemini, Llama
- Function calls para disparar acciones externas en n8n

CAPA DE AUTOMATIZACION Y LOGICA DE NEGOCIO (n8n)

n8n actua como el cerebro de automatizacion: recibe los eventos y function calls de la plataforma de voz, ejecuta logica de negocio compleja y conecta con todos los sistemas de la empresa (CRM, calendario, bases de datos, ERP, notificaciones).

3

- Webhooks para function calls durante la llamada (<500ms)
- Flujos post-llamada: transcripcion + resumen + clasificacion CRM
- Integracion con HubSpot, Salesforce, Google Sheets, Cal.com
- Notificaciones Slack / Gmail / WhatsApp segun resultado

MODELO DE INTEGRACION COMPLETO

01

Cliente llama al numero de telefono de la empresa

03

Voice AI convierte voz a texto (STT) y envia al LLM (Claude/GPT)

05

Si se necesita accion, la plataforma dispara function call al webhook de n8n

07

Al finalizar la llamada, Retell/Vapi envia post-call webhook a n8n

02

Centralita (Twilio/Telnyx) recibe la llamada y dispara webhook a Retell AI / Vapi

04

LLM genera respuesta y la convierte a voz (TTS) para el cliente

06

n8n ejecuta la logica: consulta CRM, agenda cita, registra datos

08

n8n genera transcripcion + resumen IA + actualiza CRM + notifica al equipo

RESUMEN EJECUTIVO POR PLATAFORMA

Retell AI

PRODUCCION

Latencia: ~600ms

Precio: \$0.07/min

n8n: **Nodo nativo**

LLMs: Claude, GPT, Llama

La mas equilibrada para produccion. Nodo nativo en n8n. Cumplimiento SOC2/HIPAA/GDPR.

Vapi

DEVELOPER

Latencia: <251ms

Precio: \$0.23-0.33/min*

n8n: **API / Webhook**

LLMs: 14+ proveedores

La mas rapida. Arquitectura abierta, 62M llamadas/mes. Mas compleja de configurar.

Bland AI

OUTBOUND

Latencia: ~500ms

Precio: \$0.09/min

n8n: **API / Webhook**

LLMs: GPT-4o, Claude

Especializada en outbound masivo. Constructor visual de flujos de llamada. Multilingue.

ElevenLabs

CALIDAD VOZ

Latencia: ~400ms TTS

Precio: \$0.30/1K chars

n8n: **Nodo nativo**

LLMs: GPT-4o, Claude

La mejor calidad de voz del mercado. Clonacion de voz. Agentes conversacionales propios.

TABLA COMPARATIVA DETALLADA

Caracteristica	Retell AI	Vapi	Bland AI	ElevenLabs
Latencia respuesta	~600ms	<251ms	~500ms	~400ms (TTS)
Precio base	\$0.07/min	\$0.05/min +extra	\$0.09/min	\$0.30/1K chars
Nodo nativo n8n	SI - Oficial	API/Webhook	API/Webhook	SI - Oficial
LLMs compatibles	Claude/GPT/Llama	14+ proveedores	GPT-4o/Claude	GPT-4o/Claude
SIP Trunk propio	No (usa Twilio)	Twilio/Telnyx	No (usa Twilio)	No
Cumplimiento	SOC2/HIPAA/GDPR	SOC2	SOC2	SOC2
Inbound + Outbound	SI	SI	Outbound focus	SI
Post-call webhook	SI	SI	SI	SI
Mejor para	Produccion/pymes	Desarrollo avanz.	Outbound masivo	Calidad de voz

* Vapi: coste real incluye STT (~\$0.01) + LLM (~\$0.02-0.20) + TTS (~\$0.04) + telefonía (~\$0.01) ademas del fee base \$0.05/min

OPERADORES Y CENTRALITAS PARA VOICE AI

Twilio MAS POPULAR Tipo: CPaaS Global Precio: \$0.0085/min Regiones: 100+ paises SIP: SIP Trunk + WebRTC n8n: Nodo nativo oficial Cumplim.: SOC2 / HIPAA / GDPR twilio.com VENTAJAS - Mayor ecosistema (+10M devs) - Nodo n8n nativo documentado - API REST extremadamente completa - STIR/SHAKEN nativo LIMITACIONES - Precio mas alto del mercado - No es operador propio (resale)	Telnyx MEJOR ROI Tipo: Carrier Tier-1 Precio: \$0.006/min Regiones: 100+ paises SIP: SIP Trunk nativo n8n: Tutorial oficial n8n Cumplim.: SOC2 T2 / HIPAA / GDPR telnyx.com VENTAJAS - Operador Tier-1 propio - GPUs colocadas con PoPs telecom - STT+TTS+LLM todo en uno (\$0.06/min) - Latencia mas baja del mercado LIMITACIONES - Menos conocido que Twilio - Curva de aprendizaje SIP mayor	Vonage (Ericsson) ENTERPRISE Tipo: CPaaS / UCaaS Precio: \$0.01/min Regiones: 85+ paises SIP: SIP / WebRTC / PSTN n8n: Retell AI integrado Cumplim.: SOC2 / ISO27001 / GDPR vonage.com VENTAJAS +500K empresas clientes - Integracion oficial Retell AI - SDK muy completo - Solucion enterprise consolidada LIMITACIONES - Precio medio-alto - Soporte tecnico mas lento	Netelip ESPANA / EU Tipo: Centralita Virtual ESP Precio: Segun plan Regiones: Espana + EU SIP: API Voice + SIP n8n: API Voice + webhooks Cumplim.: GDPR compliant netelip.com VENTAJAS - Operador espanol (licencia CNMC) - API Voice para n8n/Make - Transcripcion nativa Google STT - Soporte en espanol LIMITACIONES - Cobertura solo Espana/EU - Menos documentacion en ingles
--	--	---	--

CRITERIOS DE SELECCION DEL OPERADOR

Proyecto de prueba / demo rapida	Twilio	Nodo n8n nativo, \$15 credito gratis, maxima documentacion
Produccion de alto volumen / bajo coste	Telnyx	Operador Tier-1, stack completo (\$0.06/min), menor latencia
Cliente enterprise europeo	Vonage	ISO27001, reputacion enterprise, integracion Retell AI oficial
Cliente espanol / mercado canario	Netelip	Operador espanol CNMC, soporte local, API Voice para n8n/Make
Maximo control sobre la voz	Telnyx	GPUs colocadas con PoPs, STT/TTS/LLM todo en la misma red

ENFOQUE A: PLATFORM-CENTRIC (Retell AI / Vapi + n8n)

La plataforma Voice AI orquesta el pipeline de voz completo. n8n actua como backend de logica de negocio, respondiendo function calls durante la llamada y en el post-call.

- 1

Llamada entrante

Cliente llama al numero Twilio/Telnyx asignado
- 2

Recepcion centralita

Centralita enruta la llamada a Retell AI via SIP o TwiML
- 3

Saludo IA

Retell AI saluda e identifica el motivo de la llamada
- 4

Dialogo + cualificacion

Claude/GPT guía la conversacion y extrae datos del cliente
- 5

Function Call -> n8n

Retell llama al webhook n8n: checkCRM, bookAppointment...
- 6

n8n ejecuta logica

n8n consulta Google Sheets, Calendar y devuelve respuesta
- 7

Resolucion o transferencia

Agente resuelve o transfiere a humano con contexto
- 8

Post-call webhook

Retell envia transcripcion + datos a n8n para registrar CRM

CUANDO USAR ESTE ENFOQUE:

- Despliegue rapido (<1 semana)
- Alto volumen de llamadas (1000+/dia)
- Cumplimiento HIPAA/GDPR requerido
- Equipo sin experiencia en audio/DSP

ENFOQUE B: n8n COMO ORQUESTADOR COMPLETO (Twilio + Whisper + Claude + ElevenLabs)

n8n gestiona cada componente del pipeline de voz individualmente. Ofrece maximo control tecnico a cambio de mayor complejidad. Requiere optimizacion cuidadosa de la latencia.

- 1

Llamada a Twilio

Twilio recibe la llamada y dispara webhook POST a n8n
- 2

n8n recibe audio

Nodo Webhook captura el stream de audio del caller
- 3

STT: Whisper API

HTTP Request a OpenAI Whisper para transcribir a texto
- 4

LLM: Claude / GPT-4o

AI Agent node procesa el texto con contexto del cliente
- 5

TTS: ElevenLabs

HTTP Request a ElevenLabs para sintetizar la respuesta en voz
- 6

Audio a Twilio

n8n devuelve el audio a Twilio via TwiML para reproducir
- 7

Logica de negocio

En paralelo: actualiza CRM, agenda citas, registra estado
- 8

Fin de llamada

n8n guarda transcripcion completa y genera resumen con Claude

CUANDO USAR ESTE ENFOQUE:

- Necesidad de STT/TTS personalizado o en local
- Presupuesto ajustado (LLMs open source)
- Flujos de negocio muy complejos en n8n
- Equipo con experiencia en integraciones audio

STACK TECNOLÓGICO RECOMENDADO PARA PRODUCCION

TELEFONIA	Twilio o Telnyx - Numero de telefono, SIP Trunk, PSTN
VOICE AI	Retell AI (+ Claude Sonnet) - STT + LLM + TTS, function calls, webhooks
ORQUESTACION	n8n (self-hosted o cloud) - Logica de negocio, integraciones, CRM sync
DATOS	Google Sheets / HubSpot / Airtable - Registro de leads, transcripciones, datos
NOTIFICACIONES	Gmail / Slack / WhatsApp - Alertas de leads calificados al equipo

LOS DOS WORKFLOWS n8n DEL SISTEMA

WORKFLOW 1 Voice Agent Function Router Responde durante la llamada (<500ms) ● Webhook Trigger - Recibe function call de Retell AI ● Switch Node - Enruta: checkCRM / bookAppt / transfer ● Google Sheets - Lee/escribe datos del cliente en CRM ● Google Calendar - Consulta disponibilidad / agenda cita ● HTTP Request - Retell API: inicia transferencia a humano ● Respond Webhook - Devuelve JSON con resultado a Retell	WORKFLOW 2 Post-Call Processor Procesamiento al finalizar la llamada ● Webhook Trigger - Recibe call ended con transcripcion ● Claude AI Node - Genera resumen + clasificacion del lead ● IF Node - Lead caliente / tibio / frio ● Google Sheets - Guarda transcripcion, resumen, estado ● Gmail / Slack - Notifica al equipo si lead es caliente ● HTTP Request - Actualiza CRM (HubSpot/Salesforce)
--	---

PLAN DE IMPLEMENTACION (5 FASES)

FASE 1	Aprovisionamiento Alta en Twilio/Telnyx (numero tel.), Retell AI (agente base + LLM Claude), n8n (instancia self-hosted). 1-2 dias
FASE 2	Agente de voz base Configurar agente en Retell AI: prompt de sistema, voz, idioma, timeout y fallback. Conectar numero de telefono. 2-3 dias
FASE 3	Function calls + WF1 Definir function calls en Retell (checkCRM, bookAppointment, transferToHuman). Construir Workflow 1 en n8n. 3-4 dias
FASE 4	Post-call + CRM sync Construir Workflow 2 en n8n. Clasificacion de leads con Claude. Notificaciones Gmail/Slack. Test end-to-end. 2-3 dias
FASE 5	Optimizacion + monitorizacion Dashboard de métricas. Ajuste de prompts. Pruebas de carga. Documentacion de runbook operativo. Continuo

RECEPCIONISTA IA + CALIFICACION DE LEADS

ESCENARIO:
Empresa de servicios B2B. Recibe 80-150 llamadas diarias de potenciales clientes.

SOLUCION:
Agente inbound que saluda, cualifica con 4-5 preguntas clave (presupuesto, urgencia, empresa), clasifica el lead y agenda reunion con el comercial si cumple criterios.

STACK: Retell AI + Claude + Twilio + n8n + Google Sheets + Google Calendar

RESULTADOS:

- Calificacion automatica del 100% de llamadas
- Ahorro de 6h/dia al equipo comercial

n8n: WF1: checkLead, classifyLead, bookMeeting | WF2: CRM sync + Slack alert

AGENTE DE SOPORTE 24/7 CON RAG

ESCENARIO:
SaaS con 5.000 clientes activos. Soporte telefonico saturado en horario de oficina.

SOLUCION:
Agente que responde FAQs usando RAG sobre la base de conocimiento del producto. Resuelve el 70% sin intervencion humana y escala con contexto completo.

STACK: Vapi + GPT-4o + Telnyx + n8n + Pinecone (vector DB) + Zendesk

RESULTADOS:

- 70% de tickets resueltos sin agente humano
- Reduccion del 60% en coste de soporte

n8n: WF1: searchKnowledgeBase, createTicket | WF2: ticket summary + escalation

AGENTE OUTBOUND: CONFIRMACION DE CITAS

ESCENARIO:
Clinica medica con 200 citas/semana. Tasa de no-shows del 22% por falta de confirmacion.

SOLUCION:
Batch outbound: n8n lee citas del dia siguiente, lanza llamadas via Retell AI, el agente confirma/reagenda/cancela y actualiza el estado en tiempo real.

STACK: Retell AI Batch Call + Twilio + n8n + Google Calendar + Google Sheets

RESULTADOS:

- Reduccion de no-shows del 22% al 6%
- Liberacion de 3h/dia al personal admin.

n8n: Cron trigger -> Batch call Retell | WF1: updateAppointment | WF2: daily report

AGENTE COMPLETO: INBOUND + CRM + HANDOFF

ESCENARIO:
Consultora financiera. Clientes llaman por informacion, quejas y nuevas consultas. Equipo de 3 personas.

SOLUCION:
Identifica al cliente en CRM, carga su historial y gestiona la consulta. Si no puede resolverla, transfiere a humano con contexto completo (historial, transcripcion).

STACK: Retell AI + Claude + Twilio + n8n + HubSpot CRM + ElevenLabs (voz clonada)

RESULTADOS:

- Identificacion automatica del 95% de clientes
- Transferencia con contexto completo

n8n: WF1: lookupClientCRM, getHistory, transferCall | WF2: updateCRM, executive summary

PLATAFORMAS VOICE AI

Retell AI
Agentes inbound/outbound, function calls, webhooks, SIP con
Vapi
Configuración avanzada, custom LLM, latency tuning, provider
Bland AI
Outbound campaigns, visual flow builder, multilingue
ElevenLabs
TTS premium, clonación de voz, Conversational AI nativo

INFRAESTRUCTURA TELEFONICA

Twilio
TwimML, Call Control, webhooks, SIP trunking, SMS
Telnyx
Call Control v2, SIP trunk, STT/TTS/LLM integrado
Vonage / Nexmo
Voice API, Conversation API, integración enterprise
Netelip
API Voice ESP, DTMF, transcripción, webhooks para n8n

AUTOMATIZACION (n8n)

n8n avanzado
Sub-workflows, error handling, custom nodes, queue mode
Webhook design
Function calls <500ms, auth, signature verification
CRM integrations
HubSpot, Google Sheets, Airtable, Salesforce via API
AI Agents n8n
Claude/GPT con tools, RAG, memoria conversacional

MODELOS DE LENGUAJE (LLMs)

Claude (Anthropic)
Prompt engineering, tools use, streaming, system prompts
GPT-4o / OpenAI
Function calling, Whisper STT, embeddings
Llama 3 / Open Source
Despliegue local, Ollama, reducción de costes LLM
LangChain / RAG
Vectorstores (Pinecone/Qdrant), retrieval, knowledge bases

INFRAESTRUCTURA Y DEVOPS

Docker / Compose
n8n self-hosted, despliegue en VPS, configuración prod
API REST design
Diseño de endpoints, auth, rate limiting, webhooks
Git / CI/CD
Version control de workflows, deployment automatizado
Monit. / Logging
Grafana, ejecuciones n8n, alertas, dashboards operativos

INTEGRACIONES CRM Y DATOS

Google Workspace
Sheets, Calendar, Gmail, Drive - automatización completa
HubSpot
Contacts API, deals, pipelines, webhooks, automations
Salesforce
SOQL, REST API, webhooks, Lead/Contact management
WhatsApp Business
Meta API, mensajes template, notificaciones post-llamada

PROPUESTA DE VALOR

Soy especialista en diseñar, construir y operar sistemas de Voice AI que funcionan en producción real. Mi experiencia abarca la integración completa del stack: desde la configuración de la centralita SIP y el despliegue del agente conversacional, hasta la automatización de la lógica de negocio con n8n y la sincronización con los sistemas de la empresa. Entiendo que el mejor LLM del mundo no sirve de nada si no está perfectamente conectado a la infraestructura telefónica del cliente, y es exactamente en ese puente técnico donde apporto más valor.

● Conocimiento multi-plataforma
Elijo la mejor herramienta para cada cliente

● End-to-end ownership
Del número de teléfono al CRM: cada capa del sistema

● Orientado a resultados
ROI medible: ahorro de costes, tasa de resolución, 24/7